

明星分析师能否在糟糕的信息环境中做出更好的覆盖决策？

——“学海拾珠”系列之一百一十三

报告日期：2022-10-26

主要观点：

分析师：严佳炜

执业证书号：S0010520070001

邮箱：yanjw@hazq.com

分析师：吴正宇

执业证书号：S0010522090001

邮箱：wuzy@hazq.com

本篇是“学海拾珠”系列第一百一十三篇，笔者通过“分析师覆盖决策的质量”这一指标来评估明星和非明星分析师的绩效。研究发现，明星分析师的覆盖决策比非明星分析师更能预测收益，这表明明星分析师拥有高超的信息处理技能。对于信息不透明的股票，明星分析师覆盖决策对回报的预测性更强。总之，明星分析师更善于发挥信息中介的作用，这不仅可以促进投资者的资本分配，也可以促进市场效率的提高。回到 A 股市场，分析师数据一直以来都拥有独立的增量信息，如何在信息不透明的公司中进一步挖掘 alpha 来源是未来值得研究的方向。

● 明星分析师的覆盖决策比非明星分析师更能预测收益

股票的高覆盖率表明分析师坚信该股票未来会有很高的回报率，而明星分析师拥有高超的信息处理技能，覆盖决策包含的信息量比非明星分析师更大。因此，明星分析师的覆盖决策比非明星分析师更能预测收益。

相关报告

1. 《隐藏在日历异象背后的市值效应——“学海拾珠”系列之一百零五》
2. 《基金公司内部的竞争与合作——“学海拾珠”系列之一百零六》
3. 《不同的回撤指标之间存在差异性吗？——“学海拾珠”系列之一百零七》
4. 《低频交易的主动基金业绩表现如何？——“学海拾珠”系列之一百零八》
5. 《被动投资对共同基金管理能力和市场效率的影响——“学海拾珠”系列之一百零九》
6. 《共同资金流 Beta 与因子定价——“学海拾珠”系列之一百一十》
7. 《分析师反应不足和动量策略——“学海拾珠”系列之一百一十一》
8. 《股票短线交易与收益异象——“学海拾珠”系列之一百一十二》

● 对于信息不透明的股票，明星分析师覆盖决策回报的预测能力更强

明星分析师覆盖决策的信息含量取决于公司的信息环境，不透明的信息环境会导致更多的错误定价，从而为明星分析师提供了更多的机会来利用他们高超的信息处理技能，进一步丰富了覆盖决策的信息内容，并最终提升了覆盖决策回报的预测能力。

● 非明星分析师覆盖决策包含的信息是明星分析师覆盖决策内容的子集

明星分析师在媒体上的巨大曝光率使得非明星分析师可以很容易地观察和跟踪明星分析师的覆盖决策，因此，他们很有可能会直接模仿明星分析师的覆盖决策。

● 风险提示

文献结论基于历史数据与海外文献进行总结；不构成任何投资建议。

正文目录

1 引言	4
2 文献综述	7
3 研究背景、数据描述和实证模型	7
3.1 研究背景	7
3.2 数据与样本	8
3.3 估算明星分析师和非明星分析师的异常覆盖率	8
3.4 统计摘要	9
4 结果	10
4.1 异常覆盖率和未来收益	10
4.2 错误定价的校验	12
4.3 横截面异质性	14
4.4 进一步分析	15
4.5 稳健性检验	16
5 结论	17
风险提示:	17

图表目录

图表 1 样本公司数量	8
图表 2 估算明星和非明星分析师的覆盖率及汇总统计	10
图表 3 不同基金风格的竞争格局	11
图表 4 按明星型和非明星型异常覆盖率排序股票组合的风险调整收益	12
图表 5 按明星型和非明星型异常覆盖率排序的股票组合的风险调整收益	12
图表 6 预测公司的基本业绩	13
图表 7 财报公布日前后的回报率	14
图表 8 横截面异质性	14
图表 9 来自三个准自然实验的证据	15
图表 10 进一步分析：非明星分析师覆盖决策的信息内容	16
图表 11 稳健性检验	17

1 引言

明星分析师的表现是否优于非明星分析师？虽然有证据表明，明星分析师做出的盈利预测更加准确，推荐的股票也更有价值（Stickel, 1992; Desai 等人, 2000; Loh 和 Stulz, 2011; Fang 和 Yasuda, 2014），但机构投资者对分析师的排名被批评为“人气竞赛”，排名反映的仅仅是券商对分析师的认可而非分析师的卓越表现（Emery 和 Li, 2009; Brown 等人, 2015）。与之前的研究不同，笔者是根据“分析师做了什么”来评估分析师的表现。笔者这套评估方法背后的原理是，拥有高超信息处理技能的分析师可以通过识别股票（未来表现更好）来做出高质量的覆盖决策（李和苏, 2017）。因此，可以通过分析覆盖决策的信息内容来评估明星分析师是否拥有超高的信息处理技能。

通过覆盖决策来比较明星分析师和非明星分析师的表现是一种比较中肯的方式，原因主要有三点。**首先**，由于存在利益冲突，分析师的盈利预测及建议可能存在偏颇，而覆盖决策很多的反映了分析师为选择未来业绩优异的股票而所作的努力（McNichols 和 O'Brien, 1997; Hayes, 1998; Irvine, 2003; Lee 和 So, 2017）。**第二**，资源有限的分析师更偏爱前景光明的公司，因为这些公司更愿意分享信息，使分析师更容易预测收益（Das 等人, 2006）。**第三**，对一家公司的覆盖决策反映了分析师对该企业未来业绩的真实看法（见 Kothari 等人（2016）的评论），并且分析师会将该企业的业绩信息传递给市场投资者。因此，通过分析“分析师做了什么”为比较明星分析师与非明星分析师的表现提供了一种新思路。

分析师识别股票（指未来业绩表现优异的股票）的能力是不同的（Leone 和 Wu, 2007; Fang 和 Yasuda, 2014; Guan 等人, 2019）。经验丰富的分析师更能识别并覆盖未来表现优异的低价股票。反过来，熟练分析师的覆盖决策将有助于预测回报（Hong, Lim 和 Stein, 2000; Lee 和 So, 2017），这意味着覆盖决策的质量高。相比之下，虽然具有相同的想法，但能力低下的分析师很难识别出这样的低价股票。因此，覆盖决策的质量可以作为一个绩效指标来评估明星和非明星分析师识别错误股票的能力。

为了能够通过实证来衡量覆盖决策的质量，笔者采用了 Lee 和 So（2017）研发的覆盖决策模型。特别是，笔者将覆盖决策分解为：（i）可归因于公司特征的固定部分，以及（ii）由分析师对公司未来业绩的预判部分，即异常覆盖。一只股票的高异常覆盖率表明分析师坚信该股票未来有很高的回报率（Lee and So, 2017）。在明星分析师拥有高超信息处理技能的前提下，明星分析师的异常覆盖率中所包含的信息会比非明星分析师的异常覆盖率中所包含的信息更丰富。因此，笔者预计明星分析师的异常覆盖率会比非明星分析师的异常覆盖率具有更强的预测作用。

笔者的研究侧重于国内明星和非明星分析师的表现，原因有三。**首先**，国内企业对信息的自愿披露意愿及透明度相对较低（Morck 等人, 2000; Piotroski 等人, 2015）。国内资本市场的不透明性使得卖方分析师在发挥其信息中介作用时面临挑战（Chan 和 Hameed, 2006; Xu 等人, 2013）。此外，在缺乏强有力的执法和投资者保护的背景下，社会关系作为国内重要的非正式规则（Gold 等人, 2002），可能会影响分析师的意见。例如，国内分析师倾向于对与他们有关系的基金经理所持有的股票发出看好的建议（Gu 等人, 2019）。因此，在这样的背景下，分析师特别是明星分析师作为信息中介的表现如何，是一个实证性问题。**其次**，与机构投资者占主导地位的美国股市不同（Aggarwal 等人, 2011），国内股票市场散户占比超过了 50%，并占交易的大多数（Carpenter 和 Whitelaw, 2017; Jia 等人, 2017）。一般来说，信息

量较小的散户投资者会要求卖方分析师提供更多信息。因此，研究分析师在国内股市中所作覆盖决策包含的信息内容对学术界和从业者都特别有意义。第三，三个案例，包括中国放松卖空管制、谷歌退出中国等（见 4.3.2 节），使笔者能够解决内生性问题。

笔者通过分别为明星和非明星分析师构建**异常覆盖率指标**来开始分析。基于 Lee 和 So (2017) 的研究，首先，笔者将原始覆盖率表示为相关分析师（即分析师-预测对）的盈利预测的数量之和。其次，笔者将覆盖率的异常部分估计为原始覆盖率对公司特征（即公司规模、股票营业额和过去业绩）的月度横截面回归残差。为了研究明星和非明星分析师覆盖决策的质量，笔者评估了每个分析师组的异常覆盖率预测收益的能力。笔者基于每个分析师组的异常覆盖率将样本股票分为十等分，通过分析发现明星分析师和非明星分析师的异常覆盖率都能预测下个月的回报，这与**分析师的覆盖决策包含未来公司业绩信息的概念一致**。

为了比较明星分析师和非明星分析师异常覆盖率的收益预测能力，笔者进行了双重排序。首先，笔者根据明星分析师的**异常覆盖率**将股票分成四分位，然后在每个四分位中，笔者根据非明星分析师的异常覆盖率将股票也分成四分位（即 4×4 组合）。笔者发现，在控制了明星分析师的异常覆盖率后，非明星分析师的异常覆盖率不再能预测未来收益，这说明非明星分析师覆盖决策所包含的信息内容并没有超过明星分析师所含信息。然后笔者颠倒了双重排序的顺序，即首先非明星分析师的异常覆盖率进行排序，然后在每个四分位数内根据明星分析师的异常覆盖率进行排序。在控制了非明星分析师的异常覆盖率后，明星分析师的异常覆盖率仍然是未来收益的一个强有力的预测因素，这说明明星分析师的覆盖决策包含的信息内容比非明星分析师更多。为了控制可能影响未来收益的公司特征，笔者对覆盖率指标进行了 Fama-MacBeth 回归分析。笔者发现，只有明星分析师的覆盖率与未来回报率有明显的正相关。总之，笔者的研究发现明星分析师的异常覆盖率是预测未来收益的主要因素，这表明明星分析师比非明星分析师拥有更好的信息处理能力。

接下来，笔者探讨明星分析师的覆盖决策是通过什么机制来预测收益的。首先，笔者研究明星分析师是否能够预测公司基本业绩的改善。与基于错误定价的解释一致，明星分析师的覆盖决策可以预测由 F-score 所代表的企业未来两年基本业绩，并且与标准化的预期外盈余、分析师预测修正和分析师预测误差正相关。第二，笔者研究了财报公布日回报的可预测性。投资者可能对明星分析师覆盖决策传达的有关公司基本面的重要信息反应不足。当新信息（如财报公布）到来，投资者会更新他们的看法，由此产生的定价不足将被纠正（如 Noh, So 和 Verdi, 2021）。与这一机制相一致的是，笔者发现明星分析师异常覆盖率高的股票在财报公布日的回报率高于非公告日。总的来说，这些结果表明，明星分析师异常覆盖率回报的可预测性是由投资者对基本信息反应不足所驱动的。

笔者进一步探讨明星分析师覆盖决策与未来收益之间的横截面异质性，并预测明星分析师覆盖决策的信息含量是否取决于公司的信息环境。特别是，不透明的信息环境导致了更多的错误定价，为明星分析师提供了更多的机会来利用他们的技能，从而丰富了他们覆盖决策的信息内容。相反，在透明的信息环境中，价格更有可能反映公司的内在价值，这可能会抢占明星分析师覆盖决策中的信息（例如，Frankel 等人，2006；Loh 和 Stulz，2011；2018）。与这个推测一致，笔者发现明星分析师覆盖决策回报的可预测性对于信息不透明的股票（即较小的公司，没有机构所有权的公司，以及回报波动性较高的公司）更强。

然而，由于衡量信息不透明标准（如公司规模）的内生性，笔者观察到的横截面

差异可能有偏差。为了缓解这一问题，笔者利用了三个案例，对卖空试点计划的分析是非常有必要的，因为当公司的股票可做空时，潜在的卖空威胁将遏制基金误导投资者的动机，并改善公司的信息环境（Massa 等人，2015；Fang 等人，2016；Tsai 等人，2021）。相反，谷歌退出中国大陆，增加了投资者获取信息的成本（Xu 等人，2021），并恶化了公司的信息环境。笔者通过这三个实验来研究信息环境的外生变化对明星分析师覆盖决策回报的预测性的影响。

笔者发现，在放宽卖空限制之后，明星分析师的覆盖决策对收益的预测能力大大减弱。然而，在谷歌退出中国大陆后，明星分析师覆盖决策回报的可预测性明显加强。这些实验结果表明，明星分析师的覆盖决策在信息不畅的环境下能更好地预测未来的收益，这与明星分析师拥有识别错误定价股票能力的观点是一致的。

在进一步的分析中，笔者重新审视了非明星分析师的覆盖决策与未来回报之间的关系，试图解释为什么在控制了明星分析师的覆盖率之后，这种关系会消失。笔者猜想，非明星分析师可能会使用知名度高的明星分析师的覆盖决策（例如，Cooper 等人，2001；Groysberg 和 Healy，2013；Rees 等人，2015）。与预测一致，笔者发现非明星分析师覆盖决策回报的可预测性被明星分析师的滞后覆盖率所覆盖。这一发现提供了暗示性的证据，即非明星分析师能够预测回报，因为他们会遵循明星分析师的覆盖决策。

笔者还考虑了明星分析师覆盖决策收益的回报可预测性的两种替代解释。首先，明星分析师可能与他们的机构客户沟通选股思路。当机构投资者改变他们的头寸时，来自机构投资者的价格压力可能会推动明星分析师覆盖决策回报的可预测性。与该观点不一致的是，在加入机构所有权的滞后和远期变化的控制后，本文的结果仍然有效。第二种解释是，被低估公司寻求关注的行为，而不是明星分析师的技能，可能会加强回报的可预测性。特别是，被低估公司可能试图通过积极寻求明星分析师的关注来提高公司的估值。因此，分析师可能会根据这些公司的低估信号做出覆盖决策。根据先前的研究（例如，So 等人，2021 年），笔者使用**股票回购增长比率**和**内部净购买比率**作为被低估公司寻求关注行为的两个指标。笔者发现，明星分析师覆盖决策回报的可预测性并不取决于公司寻求关注的行为。

最终的测试是利用美国的数据来检验结果的普适性，并对长期以来关于明星分析师和非明星分析师相对表现的争论做出直接的贡献（如 Stickel，1992）。通过对中国数据进行类似的实证分析，笔者发现美国的明星分析师能够做出更好的覆盖决策，从而来预测未来的收益。总的来说，本文提供了令人信服的证据，在全球最重要的两个资本市场，明星分析师的表现优于非明星分析师。

本文的研究有两个贡献，有助于投资者更好地理解分析师的信息中介作用。这项研究首次使用一个新指标（覆盖决策的质量）来评估明星和非明星分析师的绩效。本文的评估方法与之前有关盈利预测和股票推荐的研究方法是完全不同的，也是对这些研究的重要补充（例如，Stickel，1992；Emery 和 Li，2009；Xu 等人，2013；Fang 和 Yasuda，2014；Guan 等人，2019）。笔者发现，明星分析师的覆盖决策在横截面上对股票收益有更好的预测，这说明明星分析师的表现优于非明星分析师。此外，当处于不透明的信息环境时，明星分析师覆盖决策回报的可预测性更强，非明星分析师做出覆盖决策则变得比较困难，这也支持了分析师输出的信息随信息环境的质量而变化的观点（Loh 和 Stulz，2018）。因此，本文的研究揭示了**明星分析师是否以及何时表现优于非明星分析师的问题**。

其次，越来越多的文献表明，分析师的产出可以预测未来的回报（Das 等人，2006；Jung 等人，2015；Lee 和 So，2017）。这意味着明星分析师能够识别因价格

和基本价值之间的差异而产生的错误定价（例如，Fama，1965；Crane 和 Crotty，2020），因此能够通过他们的覆盖决策来给投资者传递及时、准确和无偏见的信息。然而，投资者似乎对这种可能不明确的信息反应不足（例如，Jegadeesh 等人，2004；Hirshleifer 等人，2009；Giglio 和 Shue，2014；Lee 和 So，2017）。本文连同 Xu 等人（2013 年）表明明星分析师能够产生公司的特定信息。本文向前迈进了一步，研究了明星分析师覆盖决策回报的可预测性，从而为明星分析师具备识别错误定价股票能力提供了新证据。本文的证据表明，明星分析师覆盖决策中所蕴含的错误定价信号可以帮助投资者做出更明智的投资决策，并最终促进市场效率。

2 文献综述

本文基于明星分析师和非明星分析师覆盖决策的质量来评估他们的表现。本文的研究起源于 Bradshaw(2011)的呼吁。Bradshaw (P3) 指出：“我们现在几乎只关注盈利预测，这阻碍了我们对分析师角色的理解，有必要将文献的重点扩大到分析师开展的其他活动，并尝试更好地模拟他们的激励机制”。对此，笔者在评估分析师的表现时，将重点从分析师“说了什么”转移到分析师基于覆盖决策“做了什么”。本节讨论了相关的理论和实证文献，以进一步扩展这方面的研究，并提出本文的中心假设。

明星分析师的表现是否优于非明星分析师，这个问题是有争议的。一些研究表明，明星分析师提供了**更准确、更及时**的盈利预测，他们的盈利修正对股票价格的影响更大（例如，Stickel，1992；Gleason 和 Lee，2003；Xu 等人，2013）。此外，早期的证据显示，明星分析师的盈利预测受共识性预测的影响较小，这表明这些分析师是行业的领导者（Stickel，1990；1992）。此外，明星分析师发布的买入（卖出）股票建议比非明星分析师发布的建议可以产生更多的正（负）收益（例如，Loh 和 Stulz，2011；Desai 等人，2000；Fang 和 Yasuda，2014）。然而，分析师的排名经常被批评为“人气竞赛”（例如，Emery 和 Li，2009；Brown 等人，2015）。特别是大券商的分析师拥有庞大的销售队伍，可以向机构投资者推广他们的分析结果，他们比小券商的分析师更有优势，可以被评明星。这意味着，明星分析师的地位可能反映了大券商的认可，而不是分析师的卓越表现。Emery 和 Li（2009）发现，明星和非明星分析师在预测收益和提出投资建议方面能力一般。因此，之前关于分析师“说什么”的研究，对于明星分析师在履行信息中介角色方面是否优于非明星分析师，仍然没有结论。

总之，分析师的选择可以为公司的未来业绩提供参考信息，而这种信息的价值相关性取决于分析师覆盖决策的质量。如果明星分析师在处理价值相关信息和识别错误定价方面拥有高超的技能，他们就能做出高质量的覆盖决策。因此，本文预测明星分析师的覆盖决策比非明星分析师的预测回报更好。本文的中心假设如下。

假设 1：明星分析师的覆盖决策对未来收益的预测能力强于非明星分析师。

3 研究背景、数据描述和实证模型

3.1 研究背景


本节介绍了国内明星分析师的评选程序。从 2003 年开始，《新财富》杂志根据机构投资者对分析师上一年度表现的评估，发布最具影响力的金融分析师排名（例如，Xu 等人，2013；Gu 等人，2019；Li 等人，2020）。《新财富》要求机构投资者（买方公司）提名表现优异的分析师。提名过程与《机构投资者》杂志上公布的美国

全美研究团队的提名过程相类似，该团队是基于对所有行业的机构投资者的调查（Li 等，2020）。研究没有预先选择任何分析师。相反，受访者需要提供他们提名的分析师的名字。对被提名的分析师的数量没有限制。如果有两个或更多的分析师被提名，受访者需要提供一个明确的排名。《新财富》对投票进行统计，选出各自行业的前五名作为明星分析师。整个评选过程和结果由德勤会计师事务所审核。在 2003-2017 年期间，明星分析师的数量从 26 人增加到 316 人，而排名榜上的明星分析师的变化却相当高。在本文的样本中，只有大约 14% 的明星分析师保持了两年以上的明星分析师地位，而 65% 和 21% 的明星分析师分别是第一次和第二次获奖，这说明在中国成为明星分析师的竞争非常激烈。

3.2 数据与样本

本文从 CSMAR 数据库获得了公司基本面、股票收益率和分析师的有关数据。笔者从《新财富》杂志的年刊中手工收集明星分析师的名字，并将分析师的名字与 CSMAR 数据库进行匹配。本研究的样本包括在上海和深圳证券交易所上市的 A 股公司。根据 Carpenter 和 Whitelaw（2017）的建议，在实证研究中应考虑中国股市的特殊性（如停牌、ST 特殊处理）。笔者采用了以下抽样标准：i）股票在过去 12 个月内必须有超过 120 个交易日；ii）特殊处理（ST）的股票被排除在样本之外；iii）与共同基金和投资公司有关的股票也应被排除。然后，基于 Lee 和 So（2017）的研究将没有分析师跟踪的企业排除在外。最后，本文的样本由 2,935 家公司组成和 362,561 个公司月度观测值组成。图 1 显示了完整样本中的公司数量以及非明星和明星分析师涵盖的公司子样本，以及 2004 年 1 月至 2019 年 12 月期间没有涵盖的公司数量。该图显示，大量的公司没有分析师关注，明星分析师覆盖的公司数量少于非明星分析师覆盖的公司数量。S1 表示总公司数量。S2 和 S3 分别表示非明星分析师和明星分析师覆盖的企业数量。S4 表示的是没有分析师关注的企业数量。

图表 1 样本公司数量的数量



资料来源：《Can star analysts make superior coverage decisions in poor information environment?》，华安证券研究所

3.3 估算明星分析师和非明星分析师的异常覆盖率

本节介绍了笔者如何根据 Lee 和 So（2017）的实证框架来衡量明星和非明星分析师的覆盖决策。笔者首先将所有分析师分为明星和非明星。具体来说，《新财富》

去年年底公布的分析师明星从今年 1 月至 12 月 12 日保持不变（例如，Fang 和 Yasuda, 2009; 2014）。明星（非明星）分析师的原始覆盖率衡量方式为：截止到第 t 个月的六个月期间，明星（非明星）分析师在预测财年（即分析师-预测对）的盈利预测数量之和，称为原始明星（非明星）覆盖率，简称为 $StarCov$ ($NStarCov$)。选择六个月的周期是为了使大部分预测信息保持平衡。特别是，本文通过汇集公司层面的数据（有 160 万个观测值）来计算明星和非明星分析师预测所需的平均月数。本文发现，明星分析师和非明星分析师平均每隔 5.3 个月和 3.2 个月就会修改他们的预测。因此，六个月期间的盈利预测之和包含了明星和非明星分析师的大部分预测信息。

本文采用 Lee 和 So (2017) 开发的分析师覆盖率决策模型来估计明星分析师和非明星分析师的异常覆盖率。特别是，笔者对每个月与规模、流动性和动量相关的预期覆盖率成分进行了相应的原始覆盖率回归（Lee 和 So, 2017）。使用 $\log 1 + StarCov$ ($NStarCov$) 来减少异常值。具体来说，笔者做了以下两个回归来分别得到公司 i 在 t 月份的明星和非明星的异常覆盖率。

$$\log(1 + StarCov_{i,t}) = \beta_0 + \beta_1 Size_{i,t} + \beta_2 TO_{i,t} + \beta_3 MOM_{i,t} + \varepsilon_{i,t} \quad (1)$$

$$\log(1 + NStarCov_{i,t}) = \delta_0 + \delta_1 Size_{i,t} + \delta_2 TO_{i,t} + \delta_3 MOM_{i,t} + \varepsilon_{i,t} \quad (2)$$

其中， $Size_{i,t}$ 是 t 月的市值对数， $TO_{i,t}$ 是按流通股比例计算的股票成交量， $MOM_{i,t}$ 是公司 i 的累计市场调整收益。 $TO_{i,t}$ 和 $MOM_{i,t}$ 是截至 t 月的前 12 个月内的观测值。明星分析师的异常覆盖率被定义为回归残差（即 $\widehat{\varepsilon}_{i,t}$ ），在等式（1）中表示为 $AStarCov$ 。类似地，非明星分析师的异常覆盖率也被定义为回归残差（即 $\widehat{\varepsilon}_{i,t}$ ），在等式（2）中表示为 $ANStarCov$ 。 $AStarCov$ 的值越高，意味着明星分析师对某一特定公司基于它的规模、流动性和过去的表现分配了异常高的覆盖率，这说明明星分析师坚信该公司未来会有更好的表现。简而言之， $AStarCov$ 和 $ANStarCov$ 分别反映了明星和非明星分析师对公司未来前景的真实信念，并允许根据这两个指标的信息内容来评估明星和非明星分析师的表现。

图表 2 的面板 A 显示了月度 FM 回归的时间序列平均系数。为了便于比较，笔者对等式（1）和等式（2）中的所有变量进行标准化（均值为 0，标准偏差为 1）。列（1）和（2）显示，明星和非明星分析师的覆盖率与规模和动量显著正相关，与换手率负相关。规模系数是最大的，这主要是因为：分析师考虑的主要因素为股票市值（例如，Bhushan, 1989; O'Brien 和 Bhusha, 1990; Hong, Kubik 和 Solomon, 2000）。此外，第（3）列显示，与非明星分析师相比，明星分析师关注的股票数量更少且更喜欢换手和动量较低的股票。

值得注意的是，笔者的研究与 Lee 和 So (2017) 有所不同，也就是美国企业分析师的覆盖率与换手率（动量）呈正（负）相关。换手率和分析师覆盖率之间的负相关这一结论与分析师会关注佣金较高股票的观点相矛盾。然而，这种负相关却与 Andrade 等人 (2013) 的研究结果一致，他们认为股票换手反映了投资者信念的分散性。此外，动量和分析师覆盖率之间的正相关关系表明，分析师更愿意关注业绩表现更好的股票（Lee 和 So, 2017）。

3.4 统计摘要

图表 2 的面板 B 和 C 分别展示了汇总统计和相关矩阵。如面板 B 所示，一只股票平均有 36.629 个和 16.947 个由非明星分析师和明星分析师发布的盈利预测。非明星分析师的高覆盖率反映了市场上非明星分析师多于明星分析师的事实。明星和非明星分析师异常覆盖率的平均值 ($AStarCov$ 和 $ANStarCov$) 为零。面板 C 显示

了各种覆盖率指标和其他股票特征之间的相关性。明星分析师的覆盖率（StarCov）与规模（0.354）和 MOM（0.068）呈正相关，而与 TO（-0.098）呈负相关。非明星分析师的覆盖率（NStarCov）与 TO、Size 和 MOM 的相关性与 StarCov 相似。此外，关于回归分析中使用的控制变量（见图表 4），StarCov 和 NStarCov 都与 SUE 和 INST 高度正相关，而它们与 LBM、VLTY、RR 和 ACC 的相关性则相对较小。明星分析师和非明星分析师异常覆盖率之间的相关性为 0.625，表明一些股票同时吸引了明星和非明星分析师。考虑到明星分析师的覆盖决策是公开信息，可以被非明星同行学习和关注，结果并不令人惊讶。

图表 2 估算明星和非明星分析师的覆盖率及汇总统计

Panel A: Estimating abnormal star and non-star analyst coverage				Panel B: Summary statistics						
Dep. variable	(1) $\text{Log}(1+\text{StarCov})$	(2) $\text{Log}(1+\text{NStarCov})$	(3) Coeff. Difference: (1)-(2)	Variable name	Obs.	Mean	Std. Dev.	P25	Median	P75
Size	0.366*** (23.27)	0.409*** (24.34)	-0.043*** (-8.92)	StarCov	362,561	16.947	47.188	0.000	0.000	9.000
TO	-0.065*** (-11.95)	-0.046*** (-6.81)	-0.019*** (-8.74)	NStarCov	362,561	36.629	84.231	0.000	0.000	31.000
MOM	0.061*** (5.38)	0.066*** (6.30)	-0.005* (-1.89)	AStarCov	362,561	0.000	1.329	-0.891	-0.168	0.689
R ² (%)	27.34	31.65		ANStarCov	362,561	0.000	1.549	-1.177	-0.052	1.088
Obs.	362,561	362,561		Size	362,561	15.318	1.592	14.606	15.279	16.033
				TO	362,561	4.917	4.051	2.114	3.838	6.602
				MOM	362,561	0.055	0.452	-0.185	0.004	0.237
				LBM	362,561	0.485	0.158	0.373	0.509	0.615
				VLTY	362,561	0.133	0.123	0.087	0.117	0.159
				RR	362,561	0.014	0.146	-0.068	0.002	0.082
				SUE	362,561	0.084	0.978	-0.014	0.055	0.120
				ACC	362,561	0.028	0.080	-0.015	0.023	0.081
				INST	362,561	0.038	0.067	0.049	0.067	0.117

Panel C: Correlation matrix													
	1	2	3	4	5	6	7	8	9	10	11	12	13
1. StarCov	1												
2. NStarCov	0.662	1											
3. AStarCov	0.568	0.420	1										
4. ANStarCov	0.341	0.530	0.625	1									
5. Size	0.354	0.408	0.000	0.000	1								
6. TO	-0.098	-0.110	0.000	0.000	-0.117	1							
7. MOM	0.068	0.090	0.000	0.000	0.133	0.177	1						
8. LBM	0.001	0.015	0.034	0.045	0.066	-0.187	-0.111	1					
9. VLTY	-0.021	-0.015	-0.033	-0.041	0.002	0.226	0.672	-0.076	1				
10. RR	0.012	0.012	-0.018	-0.019	0.051	-0.032	0.314	-0.070	0.066	1			
11. SUE	0.252	0.319	0.185	0.212	0.375	-0.098	0.099	-0.022	-0.053	0.008	1		
12. ACC	0.060	0.064	0.032	0.040	0.063	-0.015	0.037	0.019	0.011	0.004	0.103	1	
13. INST	0.307	0.335	0.202	0.211	0.296	-0.060	0.146	0.030	0.014	0.043	0.180	0.054	1

资料来源：《Can star analysts make superior coverage decisions in poor information environment?》，华安证券研究所

4 结果

4.1 异常覆盖率和未来收益

1 单变量排序

图表 3 展示了明星分析师和非明星分析师异常覆盖率的十分位数月度回报时间序列平均值。t 月份的异常覆盖率被用来预测 t+1 月份的回报。高-低列显示了异常覆盖率最高十分位数的多头头寸和最低十分位数的空头头寸之间的回报差异。面板 A 表明明星分析师的异常覆盖率（AStarCov）与未来收益之间存在正相关。面板 B 表明，对于非明星分析师，覆盖率异常高的企业表现明显优于覆盖率异常低的企业。

图表 3 不同基金风格的竞争格局

Panel A: Returns and alphas across the deciles of the abnormal coverage of star analysts (<i>AStarCov</i>)												
	1 (Low)	2	3	4	5	6	7	8	9	10 (High)	High-Low	
EW return	1.269	1.549	1.452	1.477	1.487	1.545	1.714	1.748	1.915	2.070	0.801	(3.01)
EW 4-factor alpha	-0.099	0.014	0.077	-0.064	0.035	0.051	0.101	0.351	0.497	0.728	0.826	(6.57)
VW return	1.346	1.590	1.509	1.503	1.527	1.593	1.771	1.730	1.966	2.125	0.779	(2.38)
VW 4-factor alpha	-0.058	0.049	0.044	0.042	0.046	0.059	0.07	0.085	0.211	0.423	0.481	(4.39)
Obs.	189	189	188	189	189	189	189	189	189	189		
Panel B: Returns and alphas across the deciles of the abnormal coverage of non-star analysts (<i>ANStarCov</i>)												
	1 (Low)	2	3	4	5	6	7	8	9	10 (High)	High-Low	
EW return	1.376	1.426	1.492	1.472	1.516	1.558	1.635	1.926	1.897	2.008	0.632	(1.97)
EW 4-factor alpha	-0.221	0.006	-0.159	-0.127	0.017	0.134	0.179	0.357	0.547	0.723	0.943	(5.91)
VW return	1.506	1.526	1.533	1.508	1.581	1.608	1.678	1.900	1.943	2.068	0.562	(1.78)
VW 4-factor alpha	-0.072	-0.051	0.034	0.037	0.052	0.063	0.068	0.086	0.147	0.323	0.395	(3.66)
Obs.	189	189	189	189	189	188	189	189	189	189		

资料来源：《Passive Investing, Mutual Fund Skill, and Market Efficiency》，华安证券研究所

2 依赖性双重排序 (Dependent double sorting)

笔者之前的研究结果显示，明星分析师的异常覆盖率和非明星分析师的异常覆盖率都能预测收益。在这一小节中，笔者将评估每个异常覆盖率指标预测收益的增量能力。在分析另一个异常覆盖率指标的回报预测能力时，笔者使用依赖双重排序来控制异常覆盖率指标的排名。具体来说，笔者首先根据非明星分析师的异常覆盖率 (*ANStarCov*) 将所有公司按四分位法分成四份，然后在每个 *ANStarCov* 四分位中，笔者根据明星分析师的异常覆盖率 (*AStarCov*) 将企业也分成四份 (即 4×4 组合)。通过测试给定 *ANStarCov* 四分位数中最低和最高 *AStarCov* 组合之间 FM 因子 α 的差异，作者可以评估 *AStarCov* 回报的可预测性是否取决于 *ANStarCov*。为了更清楚地展示 *AStarCov* 是否比 *ANStarCov* 包含更多的未来收益信息，笔者计算了给定 *AStarCov* 组合的 4-factor α ，该组合包含了 *ANStarCov* 的所有股票，并比较了最高和最低 *AStarCov* 投资组合之间的 α 差异。接下来，笔者将颠倒这两种排序的顺序 (即先按 *AStarCov* 排序，再按 *ANStarCov* 排序)，以检验非明星分析师的异常覆盖率回报的可预测能力是否取决于明星分析师异常覆盖率的排名。图表 4 的面板 A1 和 A2 显示了等权组合和市值加权组合的 4-factor α ，这些投资组合分别包含了先按 *ANStarCov* 排序再按 *AStarCov* 排序的股票。为了测试相反情况是否有效，本文首先按 *AStarCov* 将企业按照四分位法分成四组，然后每组按 *ANStarCov* 将企业分为四组。面板 B1 和 B2 分别展示了等权组合和市值加权组合的 4-factor α 。

总体而言，非明星分析师异常覆盖率回报的可预测性取决于明星分析师异常覆盖率的排名。换句话说，非明星分析师所关注的股票属于明星分析师所关注股票的一部分。图表 4 有力地支持了这一观点，即明星分析师的覆盖决策比非明星分析师包含了更多有关企业未来业绩的信息。

图表 4 按明星型和非明星型异常覆盖率排序股票组合的风险调整收益

Panel A: Abnormal non-star coverage as the first sort and abnormal star coverage as the second sort										
Panel A1 Equal-weighted returns						Panel A2 Value-weighted returns				
Quartiles of <i>ANStarCov</i>						Quartiles of <i>ANStarCov</i>				
<i>ASStarCov</i>	1 (Low)	2	3	4 (High)	Avg.	<i>ASStarCov</i>	1 (Low)	2	3	4 (High)
1 (low)	-0.071	-0.083	0.020	0.546	0.238	1 (low)	-0.315	-0.193	-0.025	0.306
2	-0.196	0.215	-0.178	1.179	0.492	2	-0.367	-0.315	-1.034	1.039
3	0.586	0.738	1.156	1.404	0.995	3	-0.272	-0.289	-0.147	0.392
4 (high)	0.721	0.303	0.461	1.608	1.165	4 (high)	0.325	0.294	0.531	1.404
H-L	0.792***	0.386*	0.441*	1.062***	0.927***	H-L	0.641***	0.487**	0.556**	1.098***
<i>t</i> -statistic	(2.82)	(1.70)	(1.92)	(4.86)	(4.53)	<i>t</i> -statistic	(2.87)	(2.35)	(2.23)	(5.89)
<i>p</i> (GRS):	0.00					<i>p</i> (GRS):	0.00			
Panel B: Abnormal star coverage as the first sort and abnormal non-star coverage as the second sort										
Panel B1 Equal-weighted returns						Panel B2 Value-weighted returns				
Quartiles of <i>ANStarCov</i>						Quartiles of <i>ANStarCov</i>				
<i>ANStarCov</i>	1 (Low)	2	3	4 (High)	Avg.	<i>ANStarCov</i>	1 (Low)	2	3	4 (High)
1 (low)	-0.067	-0.013	0.531	0.554	0.244	1 (low)	-0.051	0.029	0.392	0.604
2	0.017	-0.054	0.856	1.081	0.549	2	-0.024	-0.092	-0.166	0.208
3	0.276	0.350	0.802	1.038	0.657	3	-0.039	0.150	0.490	0.593
4 (high)	0.191	0.316	0.786	1.091	0.641	4 (high)	0.128	0.162	0.535	0.674
H-L	0.263	0.329	0.255	0.537**	0.398*	H-L	0.179	0.133	0.144	0.071
<i>t</i> -statistic	(1.65)	(1.59)	(1.32)	(2.41)	(1.87)	<i>t</i> -statistic	(1.51)	(1.62)	(1.39)	(0.55)
<i>p</i> (GRS):	0.10					<i>p</i> (GRS):	0.31			

资料来源：《Can star analysts make superior coverage decisions in poor information environment?》，华安证券研究所

3 多变量回归

在本节，笔者使用 Fama-MacBeth 回归来研究明星和非明星分析师覆盖决策的信息内容。图表 5 展示了回归的结果。第 (1) - (3) 列分别表示公司规模 (规模)、股票交易额 (TO) 和过往回报率 (MOM)。(1) 列和 (2) 列显示， $\text{Log}(1+\text{StarCov})$ 和 $\text{Log}(1+\text{NStarCov})$ 的系数都为正显著。在第(4)-(6)列中，将其他常用的收益预测因素作为额外的控制变量，并再次进行回归，主要因素有账面市值比(LBM)、收益波动率(VLTY)、月度收益反转(RR)、标准化预期外盈余(SUE)、应计项目(ACC)和机构持股(INST)。

图表 5 按明星型和非明星型异常覆盖率排序的股票组合的风险调整收益

	(1)	(2)	(3)	(4)	(5)	(6)
<i>Log(1+StarCov)</i>	0.534*** (5.69)		0.299** (1.98)	0.592*** (6.84)		0.377*** (2.61)
<i>Log(1+NStarCov)</i>		0.523*** (5.11)	0.247 (1.53)		0.574*** (5.87)	0.236 (1.25)
<i>Size</i>	-0.983*** (-7.07)	-0.988*** (-7.15)	-0.987*** (-7.16)	-0.973*** (-8.30)	-0.971*** (-8.17)	-0.949*** (-8.23)
<i>TO</i>	-0.847*** (-8.28)	-0.847*** (-8.30)	-0.838*** (-8.44)	-0.704*** (-8.88)	-0.711*** (-8.92)	-0.701*** (-8.97)
<i>MOM</i>	0.425*** (6.65)	0.426*** (6.65)	0.425*** (6.64)	0.518*** (6.45)	0.519*** (6.45)	0.519*** (6.45)
<i>LBM</i>				0.046 (0.57)	0.052 (0.64)	0.046 (0.56)
<i>VLTY</i>				-0.287*** (-3.33)	-0.284*** (-3.31)	-0.282*** (-3.31)
<i>RR</i>				-0.703*** (-10.26)	-0.708*** (-10.29)	-0.703*** (-10.26)
<i>SUE</i>				0.149 (1.47)	0.149 (1.51)	0.150 (1.55)
<i>ACC</i>				-0.396** (-2.33)	-0.398** (-2.34)	-0.396** (-2.37)
<i>INST</i>				0.023 (1.29)	0.022 (1.21)	0.023 (1.29)
Cons	1.573* (1.69)	1.574* (1.69)	1.577* (1.69)	1.550 (1.61)	1.557 (1.61)	1.554 (1.61)
<i>R</i> ² (%)	7.82	7.95	8.10	11.64	11.74	11.90

资料来源：《Can star analysts make superior coverage decisions in poor information environment?》，华安证券研究所

4.2 错误定价的校验

1 异常覆盖率和企业未来基本业绩

本节主要是为了阐明明星分析师的覆盖决策在预测未来收益方面比非明星分析师表现的更好。特别是，明星分析师覆盖决策回报的可预测性可能源于他们预测企业未来业绩改善的能力，而这种改善尚未反映在股票价格上。为了检验推测，笔者基于文献（Lee and So, 2017; So et al., 2021），采用了四种方法来衡量公司的基本业绩，即 F-score，标准化预期外盈余，分析师预测修正和分析师预测误差。在图表 6 的面板 A 中，笔者使用公司的基本面数据作为综合衡量标准，也就是使用 F-score 作为因变量。高 F-score 则意味着基本面表现强劲。在图表 6 的面板 B 中，使用了三种可供选择的方法来衡量基本面情况，即标准化预期外盈余（SUE）、分析师预测修正（AFR）和分析师预测误差（AFE）。

图表 6 预测公司的基本业绩

Panel A: F-score			
	(1)	(2)	
Dep. variable	<i>One-year-ahead</i> <i>F-score</i>	<i>Two-year-ahead</i> <i>F-score</i>	
<i>Log(1+StarCov)</i>	0.056** (2.53)	0.059*** (2.67)	
<i>Log(1+NStarCov)</i>	0.047** (2.12)	0.031 (1.18)	
Controls	Y	Y	
R ² (%)	3.04	2.43	
Obs.	350,299	338,644	
Panel B: Alternative measures of fundamental performance			
	(1)	(2)	(3)
Dep. variable	<i>SUE</i>	<i>AFR</i>	<i>AFE</i>
<i>Log(1+StarCov)</i>	0.185** (2.05)	0.031*** (3.61)	0.067*** (3.09)
<i>Log(1+NStarCov)</i>	-0.110 (-1.44)	-0.002 (-0.35)	0.026* (1.75)
Controls	Y	Y	Y
R ² (%)	7.36	2.35	9.26
Obs.	274,084	263,748	267,347

资料来源：《Can star analysts make superior coverage decisions in poor information environment?》，华安证券研究所

2 财报公布前后的回报率

到目前为止，本文的研究结果表明，明星分析师的覆盖决策传达了企业未来基本面的重要信息。具体来说，明星分析师覆盖决策回报的可预测性可能代表了由于投资者对此类信息反应不足而导致的错误定价。因此，明星分析师覆盖决策所预测的回报将集中在未来的财报公布日。特别是，覆盖率水平较高（较低）的股票在财报公布日的回报率会比非公告日高（低）。为了验证这一猜测，基于 Engelberg 等人（2018）的研究给出了以下面板模型：

$$\begin{aligned}
 DRet_{i,t} = & \alpha_t + \beta_1 H_AStarCov_{i,t} + \beta_2 L_AStarCov_{i,t} + \beta_3 H_ANStarCov_{i,t} + \beta_4 L_ANStarCov_{i,t} \\
 & + \beta_5 H_AStarCov_{i,t} \times Eday_{i,t} + \beta_6 L_AStarCov_{i,t} \times Eday_{i,t} + \beta_7 H_ANStarCov_{i,t} \\
 & \times Eday_{i,t} + \beta_8 L_ANStarCov_{i,t} \times Eday_{i,t} \\
 & + \beta_9 \sum_{j=1}^{10} \gamma_j \text{LagRet}_{i,t-j} + \beta_{10} \sum_{j=1}^{10} \delta_j \text{LagRet}_{i,t-j}^2 + \beta_{11} \sum_{j=1}^{10} \rho_j \text{Vol}_{i,t-j} + \epsilon_{i,t}
 \end{aligned} \quad (3)$$

公式（3）中关注的主要变量为交互项 H_AStarCov*Eday。正的系数（β5）表明，相对于非公告日，公告日的回报率更高。图表 7 显示，H_AStarCov*Eday 的系数是正的，并且在统计学上是显著的。这意味着被低估的股价，吸引了覆盖率高的明星分析师的关注，随后会在在未来的财报公布日附近被修正，这与明星分析师覆盖决策回报的可预测性代表错误定价的观点是一致的。

图表 7 财报公布日前后的回报率

Dep. variable	DRet
High_AStarCov	0.041*** (7.72)
Low_AStarCov	0.004 (1.03)
High_ANStarCov	0.020*** (3.61)
Low_ANStarCov	-0.017*** (-3.59)
High_AStarCov*Eday	0.101*** (4.18)
Low_AStarCov*Eday	0.017 (0.82)
High_ANStarCov*Eday	0.006 (0.29)
Low_ANStarCov*Eday	0.002 (0.11)
Controls	Y
Day fixed effects	Y
R ² (%)	43.44
Obs.	3,845,508

资料来源：《Can star analysts make superior coverage decisions in poor information environment?》，华安证券研究所

4.3 横截面异质性

1 信息的不透明性

在本节中，作者将探讨明星分析师覆盖率与未来收益之间关系的横截面变化。目的主要是为了研究明星分析师覆盖决策回报的预测能力是否取决于公司的信息环境。基于 Loh 和 Stulz (2011; 2018) 的研究，使用公司规模、机构所有权和回报波动率作为信息不透明的指示指标。结果显示，小公司、机构所有权低的公司和回报波动率高的公司往往更容易受到信息不对称的影响。图表 8 显示，只有在小盘股、高波动率和无机构所有权的子样本中，Log(1+StarCov)的系数才为正。这些结果表明，覆盖决策回报的可预测性反映了分析师识别股票错误定价的能力。

图表 8 横截面异质性

	Small	Large
Log(1+StarCov)	0.405** (2.57)	0.197 (1.03)
Log(1+NStarCov)	0.051 (0.28)	0.037 (0.17)
Controls	Y	Y
Cons	0.872 (1.15)	2.129*** (2.73)
R ² (%)	8.96	15.79
Obs.	179,312	183,249
	High volatility	Low volatility
Log(1+StarCov)	0.337* (1.84)	0.131 (0.62)
Log(1+NStarCov)	0.234 (1.10)	0.085 (0.35)
Controls	Y	Y
Cons	1.699** (2.19)	1.444 (1.56)
R ² (%)	13.12	18.59
Obs.	183,534	179,027
	Without INST	INST
Log(1+StarCov)	0.310* (1.71)	0.222 (1.38)
Log(1+NStarCov)	0.048 (0.48)	0.204 (1.06)
Controls	Y	Y
Cons	4.121** (2.26)	2.361*** (3.09)
R ² (%)	11.41	15.81
Obs.	149,609	212,952

资料来源：《Can star analysts make superior coverage decisions in poor information environment?》，华安证券研究所

2 信息环境的外生性冲击

前面的横截面分析存在的问题为：信息环境的指示指标可能存在内生性。为解决这一问题，作者进行了三个外生性的案例分析，中国对卖空的放松管制是交错进行的，会对公司的信息环境产生外生性冲击。信息环境的改善不仅会减少错误定价，还会降低明星分析师覆盖决策预测收益的能力。

为了检验我们的猜测，笔者使用差异法（DiD）设计了下面的面板回归模型：

$$\begin{aligned}
 Ret_{i,t+1} = & \alpha + \beta_1 Treated1_{i,t} + \beta_2 Post1_{i,t} + \beta_3 Log(1 + StarCov)_{i,t} \\
 & + \beta_4 Log(1 + StarCov)_{i,t} \times Post1_{i,t} \times Treated1_{i,t} + \beta_5 Log(1 + NStarCov)_{i,t} \\
 & + \beta_6 Log(1 + NStarCov)_{i,t} \times Post1_{i,t} \times Treated1_{i,t} + \beta_7 Treated1_{i,t} \times Post1_{i,t} \\
 & + \beta_8 Log(1 + StarCov)_{i,t} \times Post1_{i,t} + \beta_9 Log(1 + NStarCov)_{i,t} \times Post1_{i,t} \\
 & + \beta_{10} Log(1 + StarCov)_{i,t} \times Treated1_{i,t} + \beta_{11} Log(1 + NStarCov)_{i,t} \times Treated1_{i,t} \\
 & + \delta Control_{i,t} + Industry_{i,t} + Year_t + \varepsilon_{i,t}
 \end{aligned}
 \tag{4}$$

图表 9 的面板 A 显示， $Log(1+StarCov)*Post1*Treated1$ 的系数为负(-0.371)，且在 5%以下的水平上显著相关，而 $Log(1+NStarCov)*Post1*Treated1$ 的系数在统计上不显著。这一发现表明，信息环境的外生性改善后，明星分析师覆盖决策对收益的预测能力减弱。图表 9 的面板 B 显示， $Log(1+StarCov)*Post2*Treated2$ 的系数为 0.535，具有统计学意义，而 $Log(1+NStarCov)*Post2*Treated2$ 的系数则不显著。这一结果表明，信息环境的恶化不仅会提升股票错误定价的可能性，还会提升明星分析师覆盖决策对回报的预测能力。总之，这三个实验表明，明星分析师预测收益的能力取决于信息环境的质量。

图表 9 来自三个准自然实验的证据

Panel A: Short selling deregulation		Panel B: Google's withdrawal	
$Log(1+StarCov) \times Post1 \times Treated1$	-0.371** (-2.20)	$Log(1+StarCov) \times Post2 \times Treated2$	0.535* (1.78)
$Log(1+NStarCov) \times Post1 \times Treated1$	0.182 (1.57)	$Log(1+NStarCov) \times Post2 \times Treated2$	0.128 (0.43)
$Log(1+StarCov) \times Post1$	-0.051 (1.13)	$Log(1+StarCov) \times Post2$	-0.403 (-1.34)
$Log(1+NStarCov) \times Post1$	0.056 (0.45)	$Log(1+NStarCov) \times Post2$	0.042 (0.15)
$Log(1+StarCov) \times Treated1$	0.087 (1.01)	$Log(1+StarCov) \times Treated2$	-0.307 (-1.37)
$Log(1+NStarCov) \times Treated1$	-0.005 (-0.04)	$Log(1+NStarCov) \times Treated2$	-0.127 (-0.75)
$Post \times Treated1$	0.001 (0.01)	$Post2 \times Treated2$	0.070 (0.72)
$Post1$	1.430*** (10.64)	$Treated2$	-0.414*** (-5.40)
$Treated1$	1.906*** (11.83)	$Log(1+StarCov)$	0.258 (0.87)
$Log(1+StarCov)$	-0.099 (-0.70)	$Log(1+NStarCov)$	0.080 (0.34)
$Log(1+NStarCov)$	0.109 (1.06)	Controls	Y
Controls	Y	Industry effects	Y
Industry effects	Y	Year effects	Y
Year effects	Y	R ² (%)	12.26
R ² (%)	10.53	Obs.	116,683
Obs.	156,321		

资料来源：《Can star analysts make superior coverage decisions in poor information environment?》，华安证券研究所

4.4 进一步分析

1 进一步检验非明星分析师报覆盖决策的信息内容

本节进一步探讨为什么在控制了明星分析师的覆盖率指标后，非明星分析师的覆盖率指标未能预测收益。根据以往的研究，明星分析师在媒体上的巨大曝光率使得非明星分析师可以很容易地观察和跟踪明星分析师的覆盖决策，这可能是非明星分析师的覆盖决策也能预测收益的原因。为了验证这一点，比较通过汇总过去三个

月内的分析师预测来重构两个覆盖率指标 ($\text{Log}(1+\text{NStarCov_3m})$ 和 $\text{Log}(1+\text{StarCov_3m})$) 并进行 FM 检验。图表 10 的面板 A 的第(1)列和第(2)列显示, $\text{Lag3_Log}(1+\text{StarCov_3m})$ 和 $\text{Log}(1+\text{NStarCov_3m})$ 可以单独预测收益。然而, 当这两个覆盖率指标被同时纳入回归时, 只有 $\text{Lag3_log}(1+\text{StarCov_3m})$ 的系数是显著的, 这表明非明星分析师覆盖决策回报的可预测性被明星分析师的滞后覆盖决策所包含。图表 10 的面板 B 显示, $\text{Lag3_Log}(1+\text{StarCov_3m})$ 的系数为 0.583, 显著性很高。

图表 10 进一步分析: 非明星分析师覆盖决策的信息内容

Panel A: Controlling for the past star analyst coverage			
	(1)	(2)	(3)
$\text{Log}(1+\text{NStarCov_3m})$	0.572** (2.16)		0.343 (1.44)
$\text{Lag3_Log}(1+\text{StarCov_3m})$		0.591** (2.31)	0.445* (1.81)
Controls	Y	Y	Y
Cons	1.675 (1.65)	1.593 (1.60)	1.636 (1.61)
R ² (%)	12.04	12.24	13.37
Panel B: The relationship between lagged star coverage and non-star coverage			
Dep. variable	$\text{Log}(1+\text{NStarCov_3m})$		
$\text{Lag3_Log}(1+\text{StarCov_3m})$	0.583*** (9.90)		
Size	0.407*** (6.89)		
TO	-0.008 (-1.03)		
MO	0.311*** (4.46)		
R ² (%)	51.30		

资料来源: 《Can star analysts make superior coverage decisions in poor information environment?》, 华安证券研究所

2 替代性解释

本节研究了对明星分析师覆盖决策回报的可预测性的两种替代解释。首先, 明星分析师可能会把选股的想法和他们的覆盖决策告诉他们的机构客户, 然后他们会相应地改变仓位。由此产生的来自机构投资者的价格压力可能会增强明星分析师覆盖决策回报的可预测性。其次, 定价过低的公司可能会通过积极寻求明星分析师的关注来提高企业的估值。此时分析师覆盖决策回报的可预测性只能归因于搭便车行为, 而不是分析师识别低估股票的能力。

4.5 稳健性检验

图表 11 进行了一系列稳健性校验。首先, 为了研究结果是否对子样本具有稳健性, 笔者使用了两个子样本再一次进行回归: 第一个子样本包含至少有一名分析师关注的股票, 第二个子样本包括有三名以上分析师关注的股票。面板 A 的第(1)列和第(2)列显示, $\text{log}(1+\text{StarCov})$ 的系数在两个子样本中都明显为正。第二, 笔者将券商规模作为一个额外的控制因素, 通过增加虚拟变量 (Top3 和 Top5) 来控制大券商的覆盖范围。面板 B 中的第(1)列和第(2)列显示, 在分别控制了 Top3 和 Top5 之后, 明星分析师覆盖率指标的系数仍然是正显著的, 这说明明星分析师覆盖决策回报的可预测性并不是由大券商的覆盖率驱动的。第三, 为了验证结果是否对替代指标敏感, 笔者在等式 (1) 和等式 (2) 中添加了三个额外的公司特征 (即账面价值、收益波动率和资产收益率), 并使用回归残差作为异常覆盖率的替代度量。面板 C 显示, 当模型中包含一个额外的解释变量时, R² 大约增加 1%, 进一步说明结果是稳健的。最后, 4-factor 模型可能无法完全反映预期收益。为了解决这个问题, 笔者首先计算

了 DGTW（特征基准组合法）回报，然后分别按明星和非明星覆盖率对股票进行单一排序。面板 D 显示，多空 AStarCov 策略产生的月度等权（市值加权加权）DGTW 回报为 0.528%（0.642%）。而基于多空 ANStarCov 策略，回报率则相对较低，每月的等权（市值加权）DGTW 回报率为 0.483%（0.485%）。这进一步说明本文的结果是稳健的。

图表 11 稳健性检验

Panel A: Subsample with analysts following			
	(1)	(2)	
	Analyst coverage>0	Analyst coverage>3	
<i>Log(1+StarCov)</i>	0.354** (2.33)	0.360** (2.38)	
<i>Log(1+NStarCov)</i>	0.246 (1.30)	0.253 (1.37)	
Controls	Y	Y	
R ² (%)	11.49	11.66	
Obs.	195,001	174,954	
Panel B: Control for the coverage of large brokerage houses			
	(1)	(2)	
<i>Log(1+StarCov)</i>	0.354** (2.26)	0.353** (2.24)	
<i>Log(1+NStarCov)</i>	0.234 (1.27)	0.237 (1.25)	
<i>Top3</i>	0.106*** (3.16)		
<i>Top5</i>		0.121*** (3.32)	
Controls	Y	Y	
R ² (%)	12.00	12.01	
Obs.	362,561	362,561	
Panel C: Alternative measures of abnormal star and non-star coverage			
	R ² (%)	EW Alpha High-Low	VW Alpha High-Low
Dependent variable: Log(1+StarCov)			
Size, TO, MOM, and LBM	28.21	0.767 (6.03)	0.368 (4.56)
Size, TO, MOM, LBM and ROA	29.37	0.748 (5.76)	0.294 (3.43)
Size, TO, MOM, LBM, ROA and VLT _Y	30.00	0.683 (5.17)	0.267 (2.95)
Dependent variable: Log(1+NStarCov)			
Size, TO, MOM, and LBM	33.14	0.789 (5.99)	0.297 (3.55)
Size, TO, MOM, LBM and ROA	34.63	0.712 (4.62)	0.232 (2.47)
Size, TO, MOM, LBM, ROA and VLT _Y	35.56	0.696 (4.31)	0.245 (2.61)
Panel D: DGTW returns			
		EW High-Low	VW High-Low
Abnormal star coverage		0.528 (3.31)	0.642 (4.97)
Abnormal non-star coverage		0.483 (3.55)	0.485 (3.62)

资料来源：《Can star analysts make superior coverage decisions in poor information environment?》，华安证券研究所

5 结论

本文通过构建一种新的指标（分析师覆盖决策的质量）来评估明星和非明星分析师的绩效。笔者发现，明星分析师的覆盖决策比非明星分析师更能预测收益，这表明明星分析师拥有高超的信息处理技能。同时作者还发现，对于信息不透明的股票，明星分析师覆盖决策回报的可预测性更强。总之，本文的研究结果表明，明星分析师更善于发挥信息中介的作用。

文献来源：

核心内容摘选自 Han Jin 在 Journal of Banking & Finance 上的文章《Can star analysts make superior coverage decisions in poor information environment?》

风险提示：

文献结论基于历史数据与海外文献进行总结；不构成任何投资建议。

重要声明

分析师声明

本报告署名分析师具有 PRC 证券业协会授予的证券投资咨询执业资格，以勤勉的执业态度、专业审慎的研究方法，使用合法合规的信息，独立、客观地出具本报告，本报告所采用的数据和信息均来自市场公开信息，本人对这些信息的准确性或完整性不做任何保证，也不保证所包含的信息和建议不会发生任何变更。报告中的信息和意见仅供参考。本人过去不曾与、现在不与、未来也将不会因本报告中的具体推荐意见或观点而直接或间接接收任何形式的补偿，分析结论不受任何第三方的授意或影响，特此声明。

免责声明

华安证券股份有限公司经 PRC 证券监督管理委员会批准，已具备证券投资咨询业务资格。本报告中的信息均来源于合规途径，华安证券研究所力求准确、可靠，但对这些信息的准确性及完整性均不做任何保证。在任何情况下，本报告中的信息或表述的意见均不构成对任何人的投资建议。在任何情况下，本公司、本公司员工或者关联机构不承诺投资者一定获利，不与投资者分享投资回报，也不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。投资者务必注意，其据此做出的任何投资决策与本公司、本公司员工或者关联机构无关。华安证券及其所属关联机构可能会持股报告中提到的公司所发行的证券并进行交易，还可能为这些公司提供投资银行服务或其他服务。

本报告仅向特定客户传送，未经华安证券研究所书面授权，本研究报告的任何部分均不得以任何方式制作任何形式的拷贝、复印件或复制品，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。如欲引用或转载文献内容，务必联络华安证券研究所并获得许可，并需注明出处为华安证券研究所，且不得对文献进行有悖原意的引用和删改。如未经本公司授权，私自转载或者转发本报告，所引起的一切后果及法律责任由私自转载或转发者承担。本公司并保留追究其法律责任的权利。

投资评级说明

以本报告发布之日起 6 个月内，证券（或行业指数）相对于同期沪深 300 指数的涨回撤为标准，定义如下：

行业评级体系

- 增持—未来 6 个月的投资回报领先沪深 300 指数 5%以上；
- 中性—未来 6 个月的投资回报与沪深 300 指数的变动幅度相差-5%至 5%；
- 减持—未来 6 个月的投资回报落后沪深 300 指数 5%以上；

公司评级体系

- 买入—未来 6-12 个月的投资回报领先市场基准指数 15%以上；
- 增持—未来 6-12 个月的投资回报领先市场基准指数 5%至 15%；
- 中性—未来 6-12 个月的投资回报与市场基准指数的变动幅度相差-5%至 5%；
- 减持—未来 6-12 个月的投资回报落后市场基准指数 5%至；
- 卖出—未来 6-12 个月的投资回报落后市场基准指数 15%以上；
- 无评级—因无法获取必要的资料，或者公司面临无法预见结果的重大不确定性事件，或者其他原因，致使无法给出明确的投资评级。市场基准指数为沪深 300 指数。